

DataSenado Lake Aberto

Uma leitura crítica da proposta, à luz dos objetivos que ela mesma declara

Documento revisado	DataSenado Lake Aberto — Produto, casos de uso, benefícios e visão de implantação (8 páginas, material para alinhamento de stakeholders)
Escopo	Arquitetura de dados, governança de dado público, maturidade tecnológica e posicionamento institucional
Base de comparação	Projeto <code>healthbr-data</code> (mesma arquitetura, em produção) e estado da arte em publicação de dados abertos, ago/2026
Data	27 de agosto de 2026

Veredito

A aposta arquitetural central está certa. O projeto é apresentado com uma maturidade maior do que a que possui — e é aí que está o risco.

Parquet servido como arquivo estático e consultado por DuckDB é, hoje, a escolha correta para dados abertos de escala pequena e média. Não é modismo: é a mesma arquitetura que sustenta o `healthbr-data` em produção, com 1,9 bilhão de registros e custo de infraestrutura da ordem de R\$ 40 a 150 por mês, e que convergiu como padrão em Observable Framework, Evidence.dev e nos repositórios de dados do Hugging Face. Rejeitar banco analítico central e orquestração pesada é decisão madura, não economia preguiçosa.

O problema não está no armazenamento. Está em promessas que o material ainda não pode sustentar, em ausências que um produto de dado público do Senado não pode ter, no silêncio sobre o que o Senado já opera, e em contradições internas que um leitor técnico atento encontra em uma única leitura.

O que está certo e deve sobreviver a qualquer reformulação

- **Parquet + arquivos estáticos + DuckDB.** Custo marginal por consumidor próximo de zero, superfície operacional mínima, formato aberto lido por R, Python, JavaScript e SQL.
- **Recusar infraestrutura pesada.** A maioria dos portais públicos falha por excesso de infraestrutura, não por falta.
- **Sem login.** É a decisão isolada que mais aumenta o uso real de dado público.
- **Reprodutibilidade e proveniência desde o desenho.** Raro no setor público; é o maior diferencial do projeto.
- **Tratar agentes de IA como consumidor de primeira classe.** A visão está correta e antecipada — apenas o mecanismo escolhido está imaturo.

Os riscos que exigem decisão

Grau	Risco	O que decidir
BLOQ.	Dados pessoais e reidentificação Ausente nas 8 páginas	O DataSenado publica microdados de pesquisa de opinião. Os três recursos mais vendidos — combinar bases, séries históricas completas e SQL irrestrito operado por agentes — são exatamente os vetores de reidentificação por cruzamento. E há uma assimetria estrutural: um arquivo estático não pode negar uma consulta . Uma API aplica supressão de célula e recusa; um Parquet em CDN publica o conjunto inteiro, para sempre. O INEP já restringiu microdados por esse motivo (Parecer PF/INEP 18/2022). <i>Classificar os conjuntos por sensibilidade e envolver o DPO antes da primeira publicação — que é irreversível.</i>
BLOQ.	Colisão com o que o Senado já tem	Já existem <code>dados.senado.leg.br</code> (catálogo), a API pública de dados abertos e o Plano de Dados Abertos 2026–2028 com comitê de governança. O material propõe <code>data.senado.leg.br</code> — a um caractere do catálogo existente — e rejeita “API pública pesada” num órgão que opera uma API pública. <i>Definir e escrever o posicionamento: camada analítica do ecossistema existente, não catálogo concorrente.</i>
BLOQ.	“Time travel” sem formato de tabela	A Fase 1 promete releases incrementais, manifestos, estado atual, deltas e linhagem — que é, funcionalmente, a definição de um formato de tabela. A escolha real não é “com ou sem lakehouse”, é formato padronizado ou formato caseiro . Um formato caseiro exige leitor próprio em cada linguagem e nenhuma ferramenta de terceiros funciona sem adaptação. <i>Decidir entre Iceberg com metadados estáticos, DuckLake, ou cortar a promessa de time travel — que é a opção mais barata e mais honesta.</i>
ALTO	WebMCP apresentado como pronto	O material o lista sob “o que já nasce pronto”. É uma proposta de <i>Community Group</i> do W3C, de fev/2026 — não é padrão nem <i>Working Draft</i> . A superfície da API já migrou de <code>navigator.modelContext</code> para <code>document.modelContext</code> , e o repositório oficial marca a spec como experimental. <i>Rebaixar para aposta exploratória e entregar “agent-native” agora pelo caminho estável: catálogo legível por máquina + Parquet + servidor MCP convencional, que funciona hoje em qualquer cliente.</i>
ALTO	Tetos do DuckDB-WASM não declarados	A documentação oficial do DuckDB é explícita: o cliente WASM usa uma única thread por padrão , o multithreading permanece experimental , e o WebAssembly limita a memória a 4 GB — com navegadores podendo impor menos. Não há <i>spilling</i> para disco: a consulta que não cabe é cancelada. Multithread exige isolamento cross-origin, que por sua vez dificulta o “reuso por outros sistemas” prometido. <i>Declarar o envelope de operação em números e definir agora o plano B: pré-agregados publicados como datasets de primeira classe.</i>
ALTO	Metadados de descoberta e citação ausentes	Nada sobre DCAT-AP, schema.org Dataset, licença por dataset ou identificador persistente. Um catálogo sem vocabulário padrão é mais um silo — o oposto do objetivo de “mais acesso”. <i>É a lacuna de melhor relação custo-benefício de todas: são artefatos de geração estática, encaixam no pipeline que já produz manifestos, e custam dias.</i>
ALTO	Acessibilidade — obrigação legal	O art. 63 da Lei 13.146/2015 torna obrigatória a acessibilidade em sítios de órgãos de governo; o eMAG é o modelo brasileiro. Um portal cujo conteúdo é renderizado no cliente por WASM é a classe de interface que falha em leitor de tela quando isso não é requisito desde o primeiro sprint. <i>Critério de aceite da Fase 2, não ajuste posterior. A escolha por site estático é um trunfo aqui — basta usá-la de propósito.</i>

Grau	Risco	O que decidir
ALTO	Dependência de fornecedor não declarada	workerd , Workers e sobretudo Durable Objects são Cloudflare, e Durable Objects não tem equivalente portátil — é a peça de maior <i>lock-in</i> da stack, apresentada como opcional. <i>Manter o caminho do dado em armazenamento S3 puro (migração em horas), isolar o resto atrás de uma interface e declarar onde os dados ficam fisicamente.</i>
MÉDIO	Sem dimensionamento	Seis fases sem uma data, um FTE, um valor em reais ou um volume de dado. É exatamente a informação de que o público-alvo do documento precisa para dizer sim. <i>Um quadro com ordem de grandeza por fase, mesmo com incerteza declarada de $\pm 50\%$, vale mais que nenhuma estimativa.</i>
MÉDIO	Reprodutibilidade sem mecanismo	“Provenance” e “lineage” aparecem em cinco das oito páginas, mas não se diz onde mora cada garantia nem como um terceiro a verifica sem consultar o Senado. <i>Gravar a proveniência dentro do próprio Parquet, não só no catálogo: o metadado embutido continua respondendo “de onde veio isto?” quando o arquivo já está no notebook de um jornalista, três anos depois.</i>

Seis contradições internas que um leitor técnico encontra em uma leitura

1. “Sem login” × “cotas de uso por perfil”.
2. “Evitamos API pública” × persona desenvolvedor “recebe APIs”.
3. “Leveza, menos dependências” × onze tecnologias de front-end na mesma página.
4. “Sem banco central” × time travel, deltas e catálogo.
5. “Sem servidores” × workerd e Durable Objects.
6. “Reduz superfície de ataque” × SQL arbitrário no cliente e agentes operando a interface.

A correção é editorial e barata. O custo de deixá-las é de credibilidade — e credibilidade, num material de alinhamento, é o produto.

Recomendação de sequenciamento

O documento inicia a execução pela Fase 1, já com *time travel*. A proposta abaixo intercala uma fase preliminar e reordena a camada de agentes. A lógica é única: **tudo que é irreversível deve ser decidido antes de existirem consumidores**. Layout de partição, política de dados pessoais e formato de tabela custam semanas hoje e anos depois.

FASE 0 — NOVA

Decisões e contratos (4 a 6 semanas, quase sem código). Classificação LGPD dos conjuntos e relatório de impacto para os microdados de pesquisa; decisão sobre formato de tabela; layout de partição congelado; contrato de consumo e política de reprodutibilidade; licença e forma de citação; posicionamento frente ao catálogo existente e ao Plano de Dados Abertos; envelope de operação declarado.

FASE 1

Lake mínimo, real, estreito. Dois ou três datasets publicados de ponta a ponta, sem *time travel*, com proveniência embutida no Parquet, manifesto, DCAT e página de dataset. O objetivo não é a plataforma: é provar o caminho completo com dado de verdade e usuário de verdade.

FASE 2

Portal, com acessibilidade como critério de aceite. Envelope de operação declarado, plano B de pré-agregados implementado, conformidade eMAG/WCAG AA avaliada antes do lançamento.

FASE 3

Agentes pelo caminho estável primeiro. Servidor MCP convencional sobre o catálogo e os Parquet — funciona hoje, em qualquer cliente, sem *origin trial*. WebMCP como experimento paralelo, com critério de descontinuação escrito.

FASES 4–6

Como no documento, com a ressalva de que a governança hoje alocada em “Publicação institucional” precisa estar resolvida na Fase 0, não no final.

Publicar um dataset real antes de construir a plataforma inteira é a forma mais barata de descobrir o que está errado nesta revisão e no próprio documento. O `healthbr-data` validou a arquitetura publicando um dataset e só depois generalizou; a ordem inversa é onde projetos de plataforma costumam se perder.

As perguntas que os stakeholders farão

Um material de alinhamento vale pelo que antecipa. Estas seis não estão respondidas no documento atual, e todas serão feitas:

- 1 **Isto substitui o `dados.senado.leg.br`?** Se não, qual a divisão de responsabilidade — e quem decide?
- 2 **Quanto custa, quem opera, e o que acontece se essa pessoa sair?**
- 3 **Quais dados exatamente entram?** Os microdados de pesquisa do DataSenado entram? Com que tratamento de privacidade?
- 4 **O que acontece se o WebMCP mudar de novo?** Quanto do plano depende dele?
- 5 **Se a Cloudflare mudar preço ou política, quanto tempo levamos para sair?** E onde os dados ficam fisicamente?
- 6 **Quando o cidadão vê a primeira coisa funcionando?** Uma data.

Conclusão

A proposta acerta na aposta difícil — a arquitetura de dados — e subestima as fáceis: governança, metadados, acessibilidade e posicionamento institucional. Isso é comum em projetos liderados por competência técnica genuína, e é corrigível a baixo custo **agora**.

O risco dominante não é o de a plataforma não funcionar. É o de que o material prometa uma maturidade que o projeto ainda não tem — “já nasce pronto”, “time travel”, “100% no navegador”, “sem servidores” — e a diferença entre promessa e entrega seja lida como falha de execução, quando é falha de calibragem do discurso. Num órgão público, esse erro custa mais caro que um erro de arquitetura: não se corrige com um *refactor*.

Três frases resumem o que eu mudaria: **corte o que ainda não é verdade; decida agora o que é irreversível; publique um dataset real antes de construir a plataforma inteira.**

A visão está certa. Falta ajustar o relógio entre o que se promete e o que se tem.

Sobre esta revisão. Parecer independente baseado apenas no material de 8 páginas — sem acesso a especificação, protótipo, código, orçamento ou cronograma. Achados de “ausência” podem estar resolvidos em documentos não apresentados; nesse caso viram ausências do material de stakeholders, problema menor mas ainda real. A base de comparação (`healthbr-data`) fez escolhas próprias nas mesmas questões; onde a decisão dela é apenas uma resposta possível, isso está indicado no documento técnico.

Verificação. Limites do DuckDB-WASM confirmados na documentação oficial; estado do WebMCP, no repositório do W3C Web Machine Learning CG. Versões de navegador vêm de fontes secundárias. O Plano de Dados Abertos 2026–2028 não pôde ser lido integralmente aqui e deve ser consultado antes do alinhamento institucional. **Documento técnico completo** — 17 achados, evidências e fontes: `reviews/2026-08-revisao-datasenado-lake-aberto.md`.